

1 ratecalib：多分组合格率目标的中文校准加权工具

ratecalib 用于调整人口样本或调查样本的初始权重，使一个二元指标（合格=1、不合格=0）的总体加权合格率，以及性别、城乡、学历、年龄等多个重叠分组的加权合格率，尽量接近或精确达到给定目标。

这个包特别适合以下数据结构：

- 每行代表一个样本；
- 每个样本有一个正的初始权重；
- 结果变量只有 0 和 1；
- 样本按多个分类变量交叉形成若干人口单元；
- 并非每个理论交叉单元都有样本；
- 已知总体及各边际分组的目标合格率；
- 希望通过调整权重，而不是修改原始结果变量，使加权结果靠近目标。

包提供两层接口：

1. **一步式中文友好接口**：calibrate_rates() 或 校准合格率()；
 2. **底层专业接口**：calibrate_pass_rates()，适合需要完全控制目标表和求解参数的使用者。
-

1.1 一、安装

先安装底层依赖：

```
install.packages(c("Matrix", "osqp"))
```

再安装本地源码包：

```
install.packages(  
  "ratecalib_0.2.0.tar.gz",  
  repos = NULL,  
  type = "source"  
)
```

加载包：

```
library(ratecalib)
```

macOS 若在编译 osqp 时失败，可先安装命令行开发工具：

```
xcode-select --install
```

1.2 二、最简单的使用方式

1.2.1 1. 准备数据

数据至少应包含：

- 一个 0/1 结果变量；
- 一个正的初始权重变量；
- 若干分组变量。

包内可生成一份演示数据：

```
dat <- example_rate_data(n = 5000)
head(dat)
```

中文别名也可直接使用：

```
dat <- 生成演示数据(n = 5000)
```

演示数据包含：

sex	性别
residence	城乡
education5	五段学历
age5	五段年龄
qualified	合格指标，1=合格，0=不合格
initial_weight	初始权重

1.2.2 2. 一步完成校准

```
fit <- calibrate_rates(
  data = dat,
  outcome = "qualified",
  weight = "initial_weight",

  overall = 0.70,

  groups = list(
    sex = c("男" = 0.72, "女" = 0.68),
```

```

residence = c("城镇" = 0.71, "农村" = 0.685),
education5 = c(
  "学历 1" = 0.62,
  "学历 2" = 0.66,
  "学历 3" = 0.70,
  "学历 4" = 0.74,
  "学历 5" = 0.78
),
age5 = c(
  "年龄 1" = 0.76,
  "年龄 2" = 0.73,
  "年龄 3" = 0.70,
  "年龄 4" = 0.67,
  "年龄 5" = 0.64
)
),

priority = 5,
group_priority = c(
  sex = 2,
  residence = 2,
  education5 = 1,
  age5 = 1
),

lower = 0.25,
upper = 4,
mode = "soft",
new_weight = "final_weight"
)

```

中文函数名完全等价：

```

fit <- 校准合格率(
  data = dat,
  outcome = "qualified",
  weight = "initial_weight",
  overall = 0.70,
  groups = list(
    sex = c("男" = 0.72, "女" = 0.68),
    residence = c("城镇" = 0.71, "农村" = 0.685)
  )
)

```

```
)  
)
```

查看结果：

```
fit  
summary(fit)
```

获取带新权重的数据：

```
result_data <- fit$data  
head(result_data[c("initial_weight", "final_weight")])
```

1.3 三、理论原理

1.3.1 3.1 加权合格率

设第 (i) 个样本的结果为 (y_i)，其中合格为 1、不合格为 0；初始权重为 (d_i)，校准后权重为 (w_i)。

某个分组 (j) 的加权合格率为：

$$[\hat{r}_j = \frac{\sum_i w_i I_{ij} y_i}{\sum_i w_i I_{ij}}]$$

其中 ($I_{ij}=1$) 表示样本 (i) 属于分组 (j)，否则为 0。

若目标合格率为 (r_j^*)，则目标条件可以改写为：

$$[\sum_i w_i I_{ij} (y_i - r_j^*) = 0]$$

这样，原本的比例约束就转化成了线性约束。

1.3.2 3.2 为什么不能直接把所有合格样本乘同一个倍数

因为性别、城乡、学历和年龄是重叠分组。一个样本同时属于某个性别、某个城乡类别、某个学历段和某个年龄段。改变一个样本的权重，会同时影响多个目标。

因此需要同时考虑所有目标，而不能逐组独立调整。逐组循环乘权重虽然直观，但容易出现：

- 后调整的目标破坏先前已达到的目标；
- 在多个目标之间反复震荡；
- 产生极端权重；

- 无法判断目标是否数学上相容。

1.3.3 3.3 优化目标

本包默认最小化：

$$[\sum_c \frac{(W_c - D_c)^2}{D_c}]$$

其中：

- (D_c) 是某个“人口交叉单元×合格状态”的初始权重总和；
- (W_c) 是该单元校准后的权重总和。

这意味着：在满足目标的同时，尽量少改变原始权重结构。

1.3.4 3.4 为什么先聚合再优化

若有：

- 2 类性别；
- 2 类城乡；
- 5 段学历；
- 5 段年龄；
- 2 种结果状态；

理论上最多只有：

$$[2 \times 2 \times 5 \times 5 \times 2 = 200]$$

个优化单元。

即使个人样本有几十万条，优化问题通常仍只有不超过 200 个核心变量。求解后，再把每个单元的调整倍数映射回个人样本。这既提高效率，也保证同一单元中的样本按相同比例调整。

1.3.5 3.5 人口边际保持

本包默认把原有的总体权重总量，以及各分组变量的边际权重总量作为硬约束保持不变。

例如，男性的初始权重总量为 10000，校准后仍保持 10000；但男性内部合格与不合格样本之间的权重结构可以变化，从而改变男性合格率。

这样可以防止算法为了达到合格率目标而任意改变男性、女性、城镇、农村等群体在总体中的规模。

1.4 四、软约束与精确约束

1.4.1 4.1 软约束：推荐默认使用

```
mode = "soft"
```

软约束允许目标之间存在轻微矛盾。算法会综合考虑：

- 目标误差；
- 目标优先级；
- 权重变化幅度；
- 权重上下限；
- 人口边际保持。

这通常最适合真实业务数据，因为不同来源的目标率可能存在舍入误差、测量误差或内部不一致。

1.4.2 4.2 精确约束

```
mode = "exact"
```

精确模式要求所有目标同时精确满足。只有在以下条件都成立时才适合：

- 目标之间完全相容；
- 数据结构支持所有目标；
- 每个需要调整的组中同时存在 0 和 1；
- 权重上下限足够宽；
- 缺失交叉单元没有造成结构性冲突。

精确模式失败并不一定意味着程序错误，更常见的原因是目标不可行。

1.5 五、目标优先级

在软约束模式下，priority 越大，算法越重视该目标。

```
priority = 5
```

表示总体目标优先级为 5。

```
group_priority = c(  
  sex = 2,
```

```
residence = 2,  
education5 = 1,  
age5 = 1  
)
```

表示：

- 总体目标最重要；
- 性别和城乡次之；
- 学历和年龄再次之。

优先级不是“必须达到”的开关，而是目标发生冲突时的相对权衡系数。

1.6 六、权重上下限

```
lower = 0.25  
upper = 4
```

表示：

$[0.25d_i \leq w_i \leq 4d_i]$

即最终权重最多降到初始权重的 25%，最多升到 4 倍。

常见选择：

使用场景	建议范围
非常保守	0.5–2
一般分析	0.25–4
目标差距较大	0.1–10

范围越窄，权重越稳定，但目标误差可能越大；范围越宽，目标更容易达到，但有效样本量可能明显下降。

1.7 七、校准前自动检查

一步式函数默认执行检查，也可以单独运行：

```
targets <- make_rate_targets(  
  overall = 0.70,
```

```
groups = list(  
  sex = c("男" = 0.72, "女" = 0.68)  
)  
)
```

```
check <- check_calibration_data(  
  data = dat,  
  outcome = "qualified",  
  weight = "initial_weight",  
  group_vars = "sex",  
  targets = targets  
)
```

check

中文别名：

检查校准数据(...)

检查内容包括：

- 必要变量是否存在；
- 初始权重是否为正；
- 结果变量是否只含 0 和 1；
- 分组变量是否有缺失；
- 目标类别是否在数据中存在；
- 某组是否全部为 0 或全部为 1；
- 当前各组加权合格率；
- 数据是否支持给定目标。

详细分组检查表：

check\$group_summary

目标支持情况：

check\$target_support

1.8 八、专业接口

需要完全控制目标表时，可先生成目标表：

```
targets <- make_rate_targets(  
  overall = 0.70,  
  groups = list(  
    sex = c("男" = 0.72, "女" = 0.68),  
    residence = c("城镇" = 0.71, "农村" = 0.685)  
  ),  
  overall_priority = 5,  
  group_priority = c(sex = 2, residence = 2)  
)
```

目标表结构：

variable	level	target_rate	priority
.overall	.all	0.700	5
sex	男	0.720	2
sex	女	0.680	2

然后调用底层函数：

```
fit <- calibrate_pass_rates(  
  data = dat,  
  outcome = "qualified",  
  weight = "initial_weight",  
  group_vars = c("sex", "residence", "education5", "age5"),  
  targets = targets,  
  lower = 0.25,  
  upper = 4,  
  mode = "soft",  
  lambda = 1e4,  
  new_weight = "final_weight"  
)
```

1.9 九、如何解释输出

1.9.1 9.1 目标检查

fit\$target_check

重要字段：

- target_rate：目标合格率；
- initial_rate：校准前加权合格率；
- achieved_rate：校准后加权合格率；
- error：校准后率减目标率；
- abs_error：绝对误差；
- priority：目标优先级。

误差最大的目标：

```
fit$target_check[order(-fit$target_check$abs_error),]
```

1.9.2 9.2 人口边际检查

```
fit$margin_check
```

relative_change 应非常接近 0，因为本包默认保持各边际权重总量。

1.9.3 9.3 权重诊断

```
fit$diagnostics
```

重点指标：

- initial_ESS：初始有效样本量；
- calibrated_ESS：校准后有效样本量；
- calibrated_weight_DEFF：校准后权重设计效应；
- minimum_multiplier：最小调整倍数；
- maximum_multiplier：最大调整倍数；
- cells_at_lower_bound：触及下限的单元数；
- cells_at_upper_bound：触及上限的单元数；
- maximum_absolute_target_error：最大目标绝对误差。

1.9.4 9.4 有效样本量

有效样本量定义为：

$$[ESS = \frac{(\sum iw_i)^2}{\sum iw_i^2}]$$

权重越不均匀，ESS 通常越低。若校准后 ESS 大幅下降，说明为了达到目标付出了较高的统计效率成本。

1.9.5 9.5 权重设计效应

近似权重设计效应为：

$[DEFF_w \approx 1 + CV(w)^2]$

该值越大，表示权重不均衡对估计方差的放大越明显。

1.10 十、图形诊断

目标误差图：

```
plot(fit, type = "target_error")
```

权重调整倍数分布：

```
plot(fit, type = "multipliers")
```

1.11 十一、完整案例

```
library(ratecalib)
```

1. 生成演示数据

```
dat <- example_rate_data(10000)
```

2. 设定目标并一步校准

```
fit <- calibrate_rates(  
  data = dat,  
  outcome = "qualified",  
  weight = "initial_weight",  
  overall = 0.70,  
  groups = list(  
    sex = c("男" = 0.72, "女" = 0.68),  
    residence = c("城镇" = 0.71, "农村" = 0.685),  
    education5 = c(  
      "学历 1" = 0.62,  
      "学历 2" = 0.66,  
      "学历 3" = 0.70,  
      "学历 4" = 0.74,  
      "学历 5" = 0.78
```

```

),
age5 = c(
  "年龄 1" = 0.76,
  "年龄 2" = 0.73,
  "年龄 3" = 0.70,
  "年龄 4" = 0.67,
  "年龄 5" = 0.64
)
),
priority = 5,
group_priority = c(
  sex = 2,
  residence = 2,
  education5 = 1,
  age5 = 1
),
lower = 0.25,
upper = 4,
mode = "soft",
lambda = 1e4,
new_weight = "final_weight"
)

```

3. 查看摘要

```
summary(fit)
```

4. 查看目标误差

```
fit$target_check
```

5. 查看权重质量

```
fit$diagnostics
```

6. 绘图

```
plot(fit, "target_error")
```

```
plot(fit, "multipliers")
```

7. 导出结果

```
result <- fit$data
```

```
write.csv(result, "校准后样本.csv", row.names = FALSE, fileEncoding = "UTF-8")
```

1.12 十二、常见问题

1.12.1 1. 为什么精确模式无解？

常见原因包括：

- 总体目标与分组目标不一致；
- 某组全是 0 或全是 1；
- 某些交叉单元没有样本；
- 权重上下限过窄；
- 多组目标通过重叠样本产生结构性冲突。

处理顺序建议：

1. 先运行 `check_calibration_data()`；
2. 改用 `mode="soft"`；
3. 适度放宽 `lower` 和 `upper`；
4. 调整优先级；
5. 检查目标来源及内部一致性。

1.12.2 2. 软约束误差仍然较大怎么办？

可尝试：

`lambda = 1e5`

或放宽权重范围：

`lower = 0.1`

`upper = 10`

但应同步检查 ESS 和权重设计效应。

1.12.3 3. 所有目标都应该设成最高优先级吗？

不建议。若目标之间略有冲突，全部设置同样的极高优先级并不能消除冲突，只会迫使权重产生更剧烈的变化。应根据目标来源的可靠性和业务重要性设置层级。

1.12.4 4. 没有样本的交叉人群怎么办？

算法不能凭空创造样本。缺失单元本身不一定导致失败，但若目标要求依赖这些缺失单元才能实现，就会出现不可行或较大误差。

1.12.5 5. 目标合格率是否可以来自主观设定？

技术上可以，但解释上必须谨慎。若目标来自外部总体数据，校准后结果可理解为外部信息约束下的加权估计；若目标是人为期望值，校准后的合格率主要是被设定出来的结果，不应再被表述为独立发现。

1.13 十三、推荐 workflow

实际项目中建议按照以下顺序：

1. 清理 0/1 结果变量和分组变量；
2. 确认初始权重全部为正；
3. 明确目标率来源及优先级；
4. 运行校准前检查；
5. 首先使用软约束和 0.25–4 倍范围；
6. 查看目标误差、ESS、DEFF 和边界命中情况；
7. 必要时调整优先级、lambda 或权重范围；
8. 保存最终权重和全部诊断结果；
9. 在报告中披露校准方法、目标来源和权重限制。